



戏韵千秋

京剧剧目关系与版本传承可视化实验报告

以可解释文化距离组织京剧剧本文本宇宙

课程/实验： 数据可视化课程实验

作品名称： 戏韵千秋：京剧剧本的版本传承与角色宇宙可视化

小组成员： 徐韶泽、方佳欣、王子岳、古彩妍、王心怡

中山大学·智能工程学院

2026 年 7 月

摘要

面对数量庞大的京剧剧本，按目录逐个打开文件并不难，真正困难的是看清剧目之间的关系：哪些戏共享人物和叙事母题，同名剧目在不同来源中保留或改变了什么，初次接触京剧的观众又该从哪里进入。本实验据此实现数字人文可视化系统《戏韵千秋》。系统将 1,473 个剧本、7,863 条角色记录和 40,000 个文本片段整理为可交互的文化星云：总览用于观察主题社区，版本页用于比较同名异本，AI 导览则把问答结果落回可核对的文本和节点。图谱中的位置综合考虑语义、角色结构、来源、人物网络、舞台节奏和题材谱系，因此具有可解释的关系含义。报告进一步说明三维视图的视觉深度、版本差异的计算依据和 AI 回答的证据链，并明确其数据边界。

关键词：京剧数字人文；可视分析；复合距离；版本传承；知识图谱；检索增强生成

1 问题背景与研究目标

京剧剧本既是舞台表演的文本底本，也留下了题材、角色行当、整理来源和版本等多层线索。这些信息原本分散在不同文件中。面对上千份剧本，标题检索只能帮助用户找到一部戏，却很难继续回答：它和哪些剧目相近？相近是因为故事、人物，还是来源？同名剧目又在何处发生了变化？

本实验以“**星图即戏谱**”为设计出发点，先让用户从整体关系中看见剧目，再把注意力带到版本和文本证据上。作品采用“星云总览 - 版本传承 - AI 证据”的连续路径。用户可以缩放、筛选和搜索星云；遇到《宇宙锋》《空城计》等重点剧目时，可以转入版本河流与角色比较；提出问题后，侧边栏会返回可点击的证据并高亮相关节点。图谱既呈现关系，也支持后续探索。

2 数据集与字段契约

2.1 数据规模与分析对象

系统采用最终数据版本 `v3_final`。基本分析单元为一份剧本文本，同时以规范化剧名建立“剧目组”，从而将单本浏览与同名版本比较连接起来。表1概括了数据集的主要规模。

表 1 《戏韵千秋》最终数据集概况

指标	含义	数量
剧本/版本节点	每份可分析剧本对应一个图谱节点	1,473
结构化剧本	具备可用于展示与检索的结构化字段	1,467
角色记录	剧本角色及其行当等记录	7,863
剧目组	按同名剧目归并后的分析单元	1,043
多版本剧目组	可进入版本传承比较的同名剧目组	252
文本片段	用于检索与证据回答的切分片段	40,000
来源类型	反映剧本收录、整理或流派来源的类别	33

2.2 字段契约与预处理流程

在正式解析文本前，项目先约定各类数据的粒度和主键。这样做看似基础，却决定了后续能否把搜索、图谱、版本页和 AI 证据真正连起来。数据对象包括 play、role、source、version、play_group 与 text_chunk；其中 play_id 贯穿各视图，play_group_id 用来汇集同名剧目，version_id 则让版本河流和比较矩阵能定位到具体记录。角色表还记录角色名、行当、场次位置和证据原文；剧本表保留来源、情节摘要、主题词、唱白线索和舞台提示。这些字段既供分析，也供界面直接展示。

实际处理从 PDF 解包和文本抽取开始，依次识别半结构化字段，统一剧名、来源、角色与行当写法，再建立同名版本索引。为了让问答能“说得出处”，每个文本片段还保留了剧目、版本、章节和来源等元数据。文本切片包括场次、摘要和注释，既避免把整部剧本直接送入检索，也保留足以回溯的上下文。无论用户从搜索框进入、点击星云节点，还是在侧边栏读到一条证据，最终都能回到同一份结构化数据。




图 1 从原始剧本到交互界面的数据链路




图 2 剧目搜索界面：支持以剧目、角色与相关字段进入数据集

3 数据建模与关系发现方法

3.1 复合文化距离

如果图谱只依赖文本嵌入与降维，用户只能看到“它们靠得很近”，却不知道“为什么靠得很近”。因此，本实验为每个剧目同时记录六类特征：**主题语义**（剧名、简介、注释与文本摘要）、**角色与行当结构**、**来源与版本特征**、**角色共现网络**、**舞台节奏**（场次、唱白与舞台提示）以及**题材谱系**（如三国、公案、宫廷、爱情）。两个剧目之间的距离定义为

$$d = 0.35d_{\text{semantic}} + 0.20d_{\text{role}} + 0.15d_{\text{lineage}} + 0.15d_{\text{network}} + 0.10d_{\text{rhythm}} + 0.05d_{\text{topic}}.$$


距离越小，表示两个剧目在叙事主题、角色舞台结构、来源传承或表演节奏上更接近；它不表示真实的历史年代距离。因此，星云中的邻近关系可以逐项解释，不会只停留在视觉位置上。

3.2 图构建、聚类与布局

得到复合距离后，系统为每个节点保留 $K = 12$ 个近邻，形成 KNN 图。图结构采用 Leiden 发现社区，HDBSCAN 用于识别自然形成的细星团，两种结果相互参照，减少单一算法造成的偶然分组。UMAP 只承担高维关系到二维平面的布局任务，参数为 $n_neighbors=20$ 、 $min_dist=0.08$ 和余弦度量；星团的命名与解释仍回到主题词、角色、来源和图结构统计。

图谱分为粗、细两层。粗星团先帮助用户把握三国、公案、将门、隋唐等较大的题材区域，细星团再揭示包公公案、杨家将、岳家将、明代清官权奸等更具体的子群。颜色用于区分主题社区，节点大小提示角色规模。前端将边权不低于 0.78、且不是注释

型桥接边的关系视为强关系，默认优先显示。这样可以保留值得阅读的连接，又不会让 1,473 个节点被全量边遮住。



(a) 粗星团二维视图

(b) 细星团二维视图

图 3 由宏观题材到细粒度剧目社区的双层星云编码

3.3 三维星云的坐标构成

三维视图没有重新训练三维嵌入，也没有把 Z 轴解释为某一种戏曲属性。它以二维星云为底图，将原有的布局坐标映射到 X 、 Y 平面，再生成一个稳定的视觉深度。设节点的二维显示坐标为 (x_i, y_i) ，在当前视口中的三维位置可概括为

$$X_i = 460 \hat{x}_i, \quad Y_i = -310 \hat{y}_i, \quad Z_i = 0.58S \sin(h_i + 0.11i) + 0.42S(w_i - 0.5),$$

其中 $\hat{x}_i$ 、 $\hat{y}_i$ 为归一化后的二维坐标， $S = 360$ 为深度展开尺度， h_i 由星团 ID 或剧目 ID 的固定哈希得到， i 为节点序号。 w_i 由版本数和角色数构造：

$$w_i = \min\left(1, \frac{v_i + r_i/8}{9}\right).$$

这里的 Z_i 只负责把同一平面上的点适度拉开。版本多、角色多的节点会获得略大的深度偏移，但这一偏移不能被理解为“文化距离更远”或“历史年代更早”。

渲染层使用 Three.js 的 BufferGeometry 和点精灵着色器一次性绘制节点。着色器根据点到中心的距离生成亮核与半透明光晕，节点颜色沿用粗星团或细星团的主题色；连线采用加色混合，背景另有 420 个随机星点。透视相机、初始俯仰和偏航、自动缓慢旋转、拖拽旋转和滚轮缩放共同构成可操作的三维观察空间。选中或被 AI 命中的节点会以高亮点和屏幕标记再次强调。




图 4 三维星云的坐标与渲染构成。Z 轴为视觉深度，不是额外的语义维度

3.4 线性形态与整理布局

三维星云在部分视角下呈现明显的斜向线束，这来自二维底图本身。原始布局把语义相近或关系紧密的节点排在若干带状区域，三维模式仍保留其 X、Y 相对位置；Z 轴的展开幅度有限，投影到屏幕时不会完全打散带状轮廓。强关系边又多沿这些带状区域连接，因此线性印象会更明显。这是布局和视角的共同结果，并不意味着数据只含一维结构。

为改善总览阅读，界面提供“原始布局”和“整理布局”两种模式。原始布局直接使用派生数据中的二维坐标。整理布局先按粗星团或细星团分组，把较大的组按原始 X 均值排到环形中心位置，小星团围绕父星团放置；随后用强关系进行 110 次轻量拉近，并对星团中心施加排斥力。星团内部仍保存原始坐标相对中心的角度，半径经过双曲正切压缩。该模式改变的是展示位置，不改变原始关系数据，适合首次浏览；需要观察原始分布时可切回原始布局。

4 可视化系统设计与实现

4.1 系统架构与交互流程

系统分为数据层、FastAPI 服务层、React/TypeScript 前端和 AI 导览模块。后端提供图谱、剧目、版本、搜索、星团和问答接口；前端负责渲染关系、管理筛选和详情状态；模型调用始终留在后端，以免 API Key 出现在浏览器中。用户的实际路线是“星云总览 → 星团解释 → 剧目详情 → 版本传承 → AI 提问 → 证据高亮”。无论从哪里开始，都可以继续深入，也可以顺着证据回到关系图。





图 5 星团选择与局部关系查看：通过筛选降低大规模网络的阅读负担

4.2 星云总览与三维空间表达

总览页支持二维、三维和粗细星团切换。二维视图便于寻找和比较，三维视图让各个社区的层次更直观；强关系边只在需要时显示，避免一开始就遮住节点。面对 1,000 级节点，界面将标签分层呈现，并采用按需显示连线的方式保持缩放和搜索的流畅。悬停时可以查看剧名、来源、角色数、行当构成和主题标签，点击后再进入剧目细读。



(a) 粗星团三维总览

(b) 三维强关系连线

图 6 三维星云图将主题社区与强关系结构同时置于可旋转的观察空间

5 版本传承的构建与比较依据

5.1 从同名归并到版本河流

版本传承的起点是规范化剧名。同名的剧本记录被归并为同一 `play_group`，每份文本仍保留自己的 `version_id`、来源名、版本标签、角色数和剧本 ID。版本河流按照数据中的 `version_index` 排列，展示为来源或整理序列。它不是历史年表：当数据没有可靠的出版或演出年代时，界面和报告都不把前后顺序解释成早晚关系。

版本页把四类信息放在一起阅读。版本河流回答“有哪些可比版本”；角色变形谱显示角色在不同版本中是否出现及其行当；差异卡把某一版本与参考版本的字段差异转写为短文；距离矩阵用数值概览各版本之间的相对差异。参考版本由派生数据中的 `reference_version_id` 指定，报告只说明这一事实，不把运行包中没有提供的参考版本选择规则写成结论。

5.2 差异卡和距离矩阵

差异卡的依据来自可回溯的结构化字段：新增或缺失的角色、同名角色的行当变化、来源差异、关键词增删，以及文本轮廓的变化。文本轮廓包括切片数量、场次数、文本长度、唱腔提示数、念白提示数、舞台提示数、高频角色和高频关键词。它的作用是提示用户应该去比较哪几项，而不是替代对原剧本的细读。

版本距离矩阵保存的是派生的标准化差异值，数值越大表示该对版本在所纳入的比较字段上差异越多。当前运行包交付了结果矩阵和差异字段，但未交付生成矩阵的离线计算脚本，本文不虚构其精确权重公式；矩阵只作为相对比较工具使用。这样可以避免把一个数据处理分数误写成戏曲史判断。

以《空城计》为例，数据集中有戏考、京剧丛刊和戏典三个来源版本，角色数分别为 7、4、10。矩阵显示：戏考与京剧丛刊之间的差异值为 0.728846，戏考与戏典为 0.558392，京剧丛刊与戏典为 0.575000。差异卡还能具体指出角色缺失、王平的行当标注变化，以及场次、文本长度和舞台提示的差异。数值帮助选择比较对象，角色和文本字段才是解释变化的依据。



(a) 版本传承报告与差异摘要



(b) 带证据与联动目标的 AI 导览

图 7 从版本细读到证据问答的解释性分析界面

6 AI 导览的模型与证据链

6.1 模型配置和离线索引

AI 导览通过后端调用 SiliconFlow 提供的 OpenAI 兼容接口。当前配置中，Qwen/Qwen3-8B 负责生成中文回答，BAAI/bge-m3 负责把文本和问题编码为向量；模型名与访问密钥都读取后端 .env，浏览器端不保存密钥。当前版本没有启用重排序模型。

系统在运行前已把 40,000 个文本片段编码为 1,024 维向量，并写入 FAISS 的 IndexFlatIP 索引。每个向量旁边都保留元数据，包括剧名、剧目组、版本、角色、章节、片段类型、来源和原文。查询时，问题向量和库中向量均做 L2 归一化，因此内积可作为余弦相似度使用。建立索引是离线步骤，正常提问只编码用户问题，不会重新处理全部剧本。

6.2 检索、生成与高亮

AI 回答并不把问题直接交给大模型。系统先从问题中识别版本差异、角色事实、剧情概述、星团解释、相似原因、来源事实或推荐等意图；有明确剧目或星团时，优先直接读取对应数据。随后进行字段加权的结构化检索和向量检索，当前各自最多召回 8 条证据。版本问题优先使用版本差异卡、版本河流和距离矩阵，角色问题优先角色记录和文本片段。合并、去重和按意图重排后，最多保留 12 条证据作为回答上下文。

提示词要求模型按“结论、依据、可继续探索”组织答案，并引用证据编号。后端把被使用的证据转为前端字段，附带 play_id、play_group_id、version_id 或 cluster_id。用户点击证据后，界面据此高亮剧目、版本或星团。对于证据不足，系统明确回答“当前数据不足以判断”；模型调用失败时，优先查 FAQ 缓存，缓存也不可用时返回已检

索到的纯证据，不再生成额外解释。




图 8 AI 导览的证据链。模型负责组织语言，数据记录提供回答依据

7 系统整合与界面优化

在主要功能完成后，项目又围绕真实演示路线进行了整体打磨。配色、控件密度、侧边栏层级、AI 问答框、版本河流和三维星云作为同一条探索路径的不同环节共同调整。深色背景保留星云的空间层次，题材色系帮助用户区分文化社区，信息面板以较低干扰呈现证据和操作反馈。搜索、悬停、选中、版本进入与 AI 高亮都使用相同的对象 ID，使用户可以沿着一个问题继续查下去。

在性能方面，二维视图按层绘制节点、光晕、标签和边；三维视图把节点和边写入连续缓冲区，通过 WebGL 一次渲染。强边默认可见，全部边、局部筛选和细星云视图由用户按需要打开。这样的策略把“关系很多”与“画面必须同时显示所有关系”分开处理，保证总览仍可阅读。

8 案例分析：从星团到版本传承

8.1 宏观题材社区的可解释分化

从粗星团的统计看，**公案清官与明清冤案**社区有 425 个节点，**三国群雄与智谋征战**社区有 311 个节点；隋唐、将门、水浒、神怪、爱情家庭与宫廷也各自形成了相对稳定的区域。题材词只能解释其中一部分。反复出现的核心人物、行当组合、叙事母题和来源线索共同作用，才让这些戏在图中形成可辨识的文化结构。

星团边界没有把所有熟悉的剧名做机械分类。《空城计》可以在诸葛亮、司马懿以及战争、谋略等线索构成的局部中被迅速定位；《宇宙锋》则因版本和人物结构进入公案与冤案相关的社区。这种邻近关系可以追问，也可以回到数据中验证。星云因此承担了提出分析问题的作用，而不是停留在背景画面。

8.2 同名剧目中的“稳定”与“变化”

数据中有 252 个多版本剧目组，足以支撑版本比较。针对《宇宙锋》《二进宫》《空城计》《打渔杀家》《玉堂春》和《打严嵩》等重点案例，页面不预设哪一版本“更权威”，而是把来源、角色、行当、文本摘要和差异距离并列给出。比较时可以看到，同名剧目的**叙事骨架往往仍然延续**，但角色是否出现、行当怎样标注、来源如何记录以及情节怎

样表述都会变化。这些差异对应着整理、选编和舞台实践中的不同传承路径。

这类比较也有明确边界：版本数多不等于历史时间更长。系统只按数据中可验证的来源或整理顺序展示，差异卡片只引用角色、关键词、来源和文本轮廓等派生字段。把限制写在界面与报告中，能够避免图表给出超出数据所能支持的结论。




图 9 细星团三维视图：在局部空间中观察主题、角色与版本关系的交叠

9 实验总结与特色

本实验把分散的京剧剧本文本转化为一套可交互的文化图谱。复合文化距离让“相近”可以从主题、角色、来源和舞台结构几方面解释；三维视图在二维关系上增加视觉深度，并明确保留其非语义轴的边界；版本页将同名记录的来源、角色和文本差异并置；AI 导览通过检索、证据引用和缓存回退控制生成式问答的范围。字段契约和跨视图 ID 保证搜索、节点、版本卡片与问答证据都指向同一份数据。

下一步可以补充更可靠的出版与演出年代，让版本河流具有更强的历史维度；也可以引入人工标注和专家校验，继续迭代行当与题材标签；还可以把用户的探索过程整理成面向教学的导览路线。就本次实验而言，《戏韵千秋》说明大规模戏曲文本不必只作为档案被检索，它同样可以被组织为可解释、可进入、也值得反复发现的关系空间。